

短期风电功率预测概念和模型与方法

陶玉波¹, 陈 昊¹, 秦晓辉², 孟昭军³

(1. 国网江苏省电力有限公司检修分公司, 江苏 南京 211102; 2. 中国电力科学研究院有限公司, 北京 100192; 3. 南瑞集团有限公司, 江苏 南京 211106)

摘要:随着并网风电容量的持续增加, 风电强随机性给电力系统安全稳定运行带来了挑战, 风电功率预测受到广泛的关注。文中较为全面地综述了国内外对风电功率预测的研究现状, 着重从风电预测基本理论、风电预测方法和风电预测热点研究问题3个方面展开, 主要介绍了确定性风电预测、概率性风电预测、风电爬坡事件预测、大数据和深度学习方法等方面的研究进展。

关键词:风电功率预测; 确定性预测; 概率性预测; 爬坡事件

中图分类号: TM614

文献标志码: A

文章编号: 2096-3203(2018)05-0007-07

0 引言

当今能源危机、环境污染及气候变化等问题日益凸显, 各国政府越来越关注以风力发电为代表的新能源发电技术的发展。如何立足长远, 谋划确保能源供应的可持续发展之道, 抢占未来科技创新和经济发展的制高点, 已成为世界各国重点考虑的战略问题^[1]。以风力发电为代表的新能源发电技术具有清洁、低碳、可再生等优点, 为各国开展节能减排与环境保护工作提供了强大的支撑, 其规模化发展已成为世界各国政府努力研究的方向^[2]。风力发电技术在我国发展尤其迅猛, 根据国家能源局2017年发布的数据显示, 新增并网风电装机容量为15 030 MW, 累计并网装机容量达到164 GW, 占全部发电装机容量的9.2%。风电年发电量为3057亿kW·h, 占全部发电量的4.8%, 比2016年提高了0.7%^[3]。

电力系统的调控目的是保证发电量和负荷量的动态平衡, 通过火电、水电等出力稳定机组的组合、经济调度和一次调频等调控策略, 使发电量追踪可准确预测的负荷量, 维持电网功率的动态平衡。随着电力系统中风电规模的增加, 风电具有的空间尺度分散性与时间尺度强随机波动性, 使风电机组发电量的可控性降低, 影响了电力系统中发电量追踪负荷量的能力, 给电力系统运行的安全性、稳定性和经济性带来了新的挑战。目前解决该矛盾的重要手段之一是及时准确地预测未来一段时间的风电出力, 准确的预测结果可降低成本, 提高风电并网的可靠性。

1 风电预测基本概念

1.1 预测的时间范畴

由风能的产生机理可知, 风电场采集到的风速数据在时间上一定是关联的。风是风力发电机的原动力, 经过风力发电机的发电系统, 还会保持风的强随机性、强波动性和间歇性, 风电功率数据在时间维度上也存在着一定的关联, 即前一时刻的风电功率采样值与后一时刻的风电功率采样值具有相关性^[4]。

风电功率预测可以按照预测的不同时间尺度进行分类。按照预测时间尺度可以分为4类: 超短期预测、短期预测、中期预测和长期预测。

超短期预测是时间间隔以不大于15 min为单位, 提前预测未来0~4 h的风电功率变化, 一般用于对风力发电机的控制与在线机组组合优化。

短期预测是时间间隔以分钟或者小时为单位, 提前预测未来1~3 d(1~72 h)的风电功率, 一般用于制定电网调度计划和优化常规电源的日发电计划。

中期预测是时间间隔以天为单位, 提前预测数周或者数月的风电功率, 一般用于风电场内机组和线路检修或者安装调试新的风电机组。

长期预测是时间间隔以月为单位, 提前预测整年或者数年的风电功率, 一般用于风电场规划选址及年度发电计划制定等可行性研究。

1.2 预测的空间范畴

通常风电场群所处地域分布比较广阔, 从风能产生的机理来看, 同一风带相邻位置的风速一定具有关联性。因此在同一风电场不同风电机组采集到的风电功率序列, 或者在同一风带相邻风电场间

采集到的风电功率序列,在空间上并非完全统计独立,而是具有千丝万缕的关联。

风电功率的空间相关性除了受对风速影响较大的气压、温度等自然条件环境的影响外,还受风电场所处的地形、地表粗糙度等地形条件的影响,也会受到风电场内风电机组的布置和尾流效应的影响。风电机组或者风电场之间连线越趋同于风向,则风电机组之间或风电场之间的空间相关性就越显著,因为处在同一风向上的风电机组或风电场输出的风电功率将会趋于一致,处在下风处的风电机组输出的功率与在其上风处的风电机组输出的功率时间序列相比表现出相似的波动规律,但具有一定的延时性。所以风电场上2个相邻点测得的功率时序曲线会有相似性和延时性。

文献[5]指出,随着风电场规模增大,风电场内风电机组之间距离以及数量增加,不同位置风资源的波动性相互抵消,因此风电场总出力的波动性减弱。对风电场群进行风功率预测,为了获得高精度的预测结果,须要考虑风电功率的空间相关性。

2 风电功率预测法

2.1 确定性风电功率预测方法

确定性预测是指运用某种预测模型依据当前时刻的各种测量值,计算未来某时刻风电功率预测具体值。按照预测模型的不同,可以分为3类:物理预测法、统计学习预测法和混合集成预测法^[6-7]。

2.1.1 物理预测法

物理预测法本质上是数值天气预报(numerical weather prediction, NWP),基于制定风电场高精度的数值天气预报的物理模型,主要依据大气层空气运动的情况提炼出风速的影响因素,例如:风向、空气压强、空气温度、空气湿度等作为预测模型的参考输入变量,采用数值计算方法,通过设置计算初值和计算边界条件,以实现求解出反映空气运动过程的流体力学方程组合热力学方程组的计算目标,进一步计算出各参考变量的分布,最终制成数值天气预报结果,换算至风力发电机轮毂处的等效风速,利用功率曲线得到风机的输出功率。

物理预测法的优点在于不需要长期大量的历史数据就能得到预测结果,特别适用于新建风电场的预测和中长期风电功率的预测,短期预测和超短期预测不适用单纯的物理方法进行预测,因为气象条件是不稳定系统,演变需要数小时才能被监测到,并且NWP需要进行大量的耗时计算,目前较少单纯使用该方法进行超短期预测。

提升NWP精度须要提高偏微分方程组建模的准确性,提高物理网格划分密度和提高计算初值和计算边界条件的准确性^[8]。

2.1.2 统计学习预测法

统计学习预测法本质上是通过历史风电功率、历史风速、风向、气压、温度等数据与风电场的风电功率或者风速建立一定的关系来进行推断,要求预测对象演化速度较为缓慢,其建模方法简单有效,被广泛应用于超短期和短期预测。风电功率序列是典型的非线性时间过程,风电场中多台风机由于尾流效应等影响的存在,风电功率序列间还包含着一定的空间信息,通过深入挖掘数据序列中时间和空间的信息有助于提高预测精度。近年来,基于统计学习的方法发展迅速,这种方法采用“黑箱”的建模思路,模型函数不是以解析的形式显示描述,而是用人工智能的方法找出输入与输出的对应关系,通过对长期积累的历史数据的学习,建立输入与输出的关系,进而采用这种方式建立的模型进行预测,具有适应性强,便于推广等优点。常见的统计学习预测方法有时间序列分析法、人工神经网络法(artificial neural network, ANN)、支持向量机法(support vector machine, SVM)、卡尔曼滤波法、考虑时空相关性法等方法。

(1) 时间序列分析是对大量的时间数据序列进行参数估计、模型识别、检验等过程后确定一个数学模型进行预测。目前文献中主要有经典时间序列分析模型和现代时间序列分析模型两大类,经典时间序列分析模型有自回归模型、滑动平均模型、自回归积分滑动平均模型、分数自回归滑动平均模型;现代时间序列分析模型有广义自回归条件异方差模型、随机波动模型、平滑转换自回归模型等。风电功率和风速数据通常是非平稳时间序列,应用时间序列分析模型前一般需要经过差分之后才能变为平稳时间序列^[9-11]。文献[12—13]研究了风电功率序列的二阶矩,提出了基于广义自回归条件异方差模型的风电功率预测方法,使用条件最大似然估计法辨识参数,预测结果优于经典时间序列分析模型。文献[14]基于广义自回归条件异方差偏度峰度模型的风电功率预测新方法,针对风电时间序列高阶条件矩时变性的检验问题,提出链式检验新方法,结合提出的实用化参数约束处理方法,提升了预测效果。

(2) ANN是通过复制人类大脑工作过程的方法,用某种结构连接需要处理的大量元件,有较强的自学习、自组织、自适应的能力,可以处理复杂的

非线性问题。如何防止人工神经网络算法陷入局部最优和过学习的问题,是其改进的研究方向。在1996年就有学者将ANN用于风功率的超短期预测^[15]。后来,众多学者将ANN模型进行了不同的改进,预测精度不断提高^[16-17]。

(3) SVM是在统计学习理论的基础上发展的一种学习方法,基于结构风险最小化原则,适用于小样本情形下模型的建立。SVM预测方法通过核函数,将样本空间的输入映射到高维特征空间,解决了传统方法中的维数灾难、学习时间长、模型适应性弱等问题。文献[18]提出了一种新的 N -SVM回归模型,对传统的SVM核函数进行了修正,进一步提高了预测精度。

(4) 卡尔曼滤波法通过建立状态空间方程,需要已知噪声的统计特征,将预测对象作为状态变量。卡尔曼滤波具有稳定性高、无偏性等特点,但如何得到噪声的统计特征是其方法的难点。卡尔曼滤波在预测过程中不断地进行修正,不需要存储大量数据,其计算速度非常快。文献[19]通过卡尔曼滤波法对NWP的结果进行修正,取得了较好的预测结果,使预测的均方根误差从未修正的17.73%降低至11.32%。

(5) 考虑时空相关性的方法基于多个相互关联的风电场信息共享的数据平台,风电功率时间序列在不同空间点之间有很强的关联性,根据由风电场内风电机组间空间排布关系推导出的空间相关矩阵,得到其他风电机组的风速、风向,进一步可得到风电功率预测值。文献[20]分析了新西兰不同地形条件下风速数据,发现不同地表粗糙度下风速的相关性不同。将不同地形特征的影响分为4类:第一类为地势平坦区域,不同点的风速相关性较强;第二类为峡谷地区,不同点的风速相关性根据不同地形条件不同;第三类为山区,地表粗糙度较高,遮挡物多,风速相关性较弱;第四类为不规则地形区,风速相关性不确定。文献[21]得出了月份、季节的不同,风速表现出的特征模式不同的结论。

2.1.3 集成预测法

集成预测法是目前风电功率研究的热点方法之一,一般分为多模型组合和多算法混合。多模型组合由于它结合各个单一模型的有用信息,所以预测精度有一定的提高,其主要目的是对各种单一模型取长补短,利用每种模型的优点组合起来超越单一模型的预测精度。其研究难点在于如何稳定的发挥某一种模型的优点和各个单一模型之间如何组合。文献[22]基于最大信息熵的原理,建立了基

于多种预测模型的风电功率组合模型,相对于单一的模型来说,文中提出的方法提高了预测精度。文献[23]建立基于支持向量机和人工神经网络的预测模型,通过采用不同确定性权重因子来对预测模型进行混合。研究表明,这种组合方法虽然与权重的选择有一定的关系,但是不同的权重下均能够降低预测误差。多算法混合是针对风电功率的数据特点,针对算法本身的优势,将多种算法进行混合,以便在一次预测过程使用,提高预测精度。文献[24]采用经验模态分解和人工神经网络进行混合,首先对风电功率序列进行分解,进而针对分解后的子序列分别使用人工神经网络进行预测,再将各个子序列的预测结果进行重构,最终得到功率预测结果,研究结果表明效果较好。

2.2 概率性风电功率预测方法

风电功率预测的最大挑战是存在预测误差。电力系统高效安全稳定运行需要电网功率时刻与负荷平衡,风电功率预测的不确定性给这一目标的实现带来了困难,为了更有效保证电力系统运行,需要预测模型能在一定程度上描述预测结果的不确定性。概率预测方法是确定性预测方法的拓展,风电功率的数据序列可以看作是随机过程,可以在随机优化的框架下进行研究,使用概率密度函数和概率分布函数来描述风电功率的不确定性。与风电功率的确定性单点预测相比,概率性风电功率预测方法不仅能提供预测结果变动范围,还能估计出确定性预测值出现的概率,相比于确定性预测方法,能提供更多的量化信息表征不确定性,有助于发电计划的提前安排,确保电力系统安全稳定运行。概率性风电功率预测方法可以预测风电功率按照多大的概率落在某个区间内,预测方法一定时,预测的区间越大,预测值落在区间内的概率越大。

概率性预测方法繁复多样^[25-26],根据建模时是否适用确定性预测结果,可以分为风电功率概率预测和确定性风电功率预测误差概率预测。前者直接在建模时根据实测数据得到风电功率概率分布;后者根据确定性预测误差为研究对象,得出误差的概率分布,迭代回确定性预测结果中,得到概率预测区间。

如何求得研究对象的概率分布,可以根据研究对象概率分布的已知情况,分为参数估计、非参数估计和半参数估计。

(1) 参数估计即风电功率或预测误差概率分布可以用已知的概率密度函数来描述,由此可以将概

率性风电功率预测问题转化为参数估计的问题,计算复杂度较低,但是由于假设了已知的概率分布,当实际情况与假设不一致时,预测结果将不理想。

(2) 非参数估计即不假设风电功率或预测误差概率分布已知,通过数据挖掘的方法,比如核密度估计法^[27]来计算分布函数。由于不存在假设不合理的情况,预测效果比参数估计的效果好,但是计算复杂度高。

(3) 半参数估计利用某种理论或先验知识限制对风电功率或预测误差概率分布的具体形式进行限制。如运用得当,有望改善预测精度,且计算复杂度显著低于非参数估计。

概率性风功率预测方法与确定性预测中统计学习方法相结合,可以将确定性预测结果拓展到区间预测。文献[28]提到的极限学习机(extreme learning machine, ELM)就是其中一种,以广义逆矩阵理论为基础提出的新单隐层前向网络,与传统的ANN相比,具有较好的非线性拟合能力,可以通过非线性映射直接计算出风电功率区间预测结果,计算复杂度也不高。

3 风电功率预测热点问题

3.1 风电爬坡事件预测

风电爬坡事件是指风电功率在较短的时间尺度内发生较大变化,严重影响电力系统安全稳定运行。一般使用爬坡方向、爬坡时间、爬坡率、爬坡幅度和起始时间这5个量来描述风电爬坡事件^[29]。将风电功率突然增大的事件称为上爬坡事件,主要由于大气低空急流、低压气旋、雷雨等极端气象事件引起;将风电功率突然变小的事件,称为下爬坡事件,主要由于风机风速过大,超出了切出风速阈值,机组被迫退出运行引起。风电爬坡事件是风电功率强随机性、强波动性和间歇性的极端体现,美国曾在2008年2月发生过由于风电场发生爬坡事件,造成频率下降至59.85 Hz,切除负荷1150 MW的事件。进行爬坡事件预测,可以提前从风电机组本体和电网控制角度来调节爬坡事件,降低危害。爬坡事件预测有直接预测和间接预测两种方法:

(1) 直接预测法是从风电场历史数据中挑选出爬坡数据,使用机器学习模型进行学习,直接预测爬坡事件。此方法需要大量爬坡数据,但实际上爬坡事件是小概率极端事件,发生次数有限,故训练集缺失比较严重。

(2) 间接预测法是先进行风功率预测,再根据爬坡事件的定义进行识别。目前间接预测法为爬

坡事件预测的热点内容。常用的预测方法有基于统计学习模型、基于NWP的物理模型和混合集成预测方法。

文献[30]采用改进旋转门算法对爬坡事件检测,使用动态规划算法对传分段时间区间进行优化整合,表明改进旋转门算法能够有效地检测出风电功率爬坡事件,并且比传统旋转门算法的表现效果更好,同时该算法比L1滑窗算法消耗更少的计算时间。文献[30]提出了采用多个NWP模型的风电爬坡预测结果较好。文献[32]利用原子稀疏分解对原始数据进行分解后分别采用自预测和BP神经网络进行预测,提高了爬坡预测的精度。

3.2 基于大数据的深度学习预测

深度学习是机器学习的一个分支。主要特点是通过多层次的学习而得到对于原始数据的不同抽象层度的表示,进而提高分类和预测等任务的准确性。深度学习的一个重要特点是不需要人工输入或标注特征(标签),而是通过海量数据自动学习特征,也就是无监督学习,所以深度学习常常和大数据联系在一起^[33-35]。深度学习具有强大的搜索计算能力,为提高风电功率预测的准确性增加了一种可行的方法。目前深度学习已在电力系统的静、动态安全评估、故障诊断、负荷预测、线损计算、经济调度控制策略等方面开展应用。

与传统前馈人工神经网络相比,深度学习使用多个隐含层,前一层可使用无监督学习算法获得数据特征,输入到下一个隐含层,从而通过多个隐含层逐步抽象出数据特征。所以深度学习算法有强大的处理非线性问题和特征提取的能力,适合处理具有非线性和非平稳特征的风电功率时间序列。

大数据是深度学习应用的基本条件。大数据理论可以对全时空数据集内关联关系进行有效识别和提取,一定程度上弥补物理因果关系分析的不足,但当前电力系统已有的数据采集系统还难以完全满足应用需求,如何获取高质量的全时空数据集,仍然制约着这一技术的应用。

文献[36]将层叠受限玻尔兹曼机深信度网络用于风电功率预测,取得了不错的预测效果。

3.3 预测评价

投入商业运行的风电场需要接受国家能源部门的监管,满足电网的调度要求,对风电场运行是否满足调度并网要求进行奖惩。对常规风功率点预测的评价标准主要有平均绝对误差(average absolute error, MAE)、均方误差(mean square error, MSE)、均方根误差(root mean square error, RMSE)、

标准差 (standard deviation error, SDE) 等。MAE 表示预测误差的实际情况; MSE 和 RMSE 表示误差的分散程度; SDE 表示误差分布的标准差估计。国家能源局发布的《风电场功率预测预报管理暂行办法》中要求, 风电场功率预测系统提供的日预测曲线最大误差不超过 25%, 实时预测误差不超过 15%, 全天预测结果的 RMSE 应小于 20%。

概率性风功率预测的评价标准主要从概率性预测结果的可靠性和预测区间应尽量窄两方面考量。即要求风功率落在预测区间的概率应尽可能接近置信度, 且不确定性尽量集中, 若预测区间过大, 将对决策没有任何意义。

当前风电预测模型理论高精度和应用时的实际精度之间存在着一条鸿沟, 该问题影响了风电预测模型的工程实际应用。对风电预测方法的正确评价, 是弥合这条鸿沟的重要手段。当前文献中最常见的 MAE、MSE 比较法, 可能存在着受结果随机性干扰、透支使用建模以外数据、不能评价不对称损失等问题。

IEEE PES 能源预测工作组长期致力于预测评价方面的研究, 结合三届 (2012, 2014 和 2017) 具有广泛影响力的全球能源预测竞赛对该问题进行了一系列有价值的探索^[37-38]。

CIGRE C1.32 工作组针对包括预测评价在内的能源预测技术开展了广泛的国际调研工作, 通过深入分析调查问卷后发现: 风电等新能源发电技术的大量应用将对能源预测带来深远的影响^[39]。

4 结论

文中从风电功率的特点出发, 对风电功率预测进行了分类归纳, 对不同预测方法的发展水平进行了梳理和总结, 对风电功率预测的研究热点进行了探讨, 得出以下结论:

(1) 风功率预测的主要目标是尽可能快速准确的提供预测值, 减少弃风, 优化调度计划和机组组合, 使风电机组尽可能多的并网。

(2) 统计学习预测方法在超短期、短期预测风功率预测领域广泛使用, 但在某些复杂地形、范围较大风电场的预测中, 与物理预测方法结合使用, 预测效果会更优。

(3) 概率性风电功率预测是未来风电预测的重点研究方向, 该方法能对风电功率预测不可避免的预测误差提供较为详细的描述, 为电力系统运行控制提供更加全面的风电功率信息支撑。

(4) 风电功率爬坡事件预测能降低发生爬坡事

件时对电力系统的影响, 在对风电功率进行预测的同时, 也要对爬坡事件进行识别。目前爬坡预测研究处于起步阶段, 是需要关注的重要研究方向。

(5) 大数据技术和深度学习的发展对提高风电在不同时间尺度和空间的预测精度有积极作用。

(6) 提高预测精度一直是风电预测领域追求的目标。随着预测模型的逐渐完善和新模型的提出, 预测精度逐步提高, RMSE 从 30% 以上降到 10% 以下, 但精度提高的程度日渐式微, 风能本身具有的强随机性、强波动性和间歇性是实现这一目标的主要困难, 也是未来一段时间研究的重点。

参考文献:

- [1] 史 丹. 新能源产业发展与政策研究[M]. 北京: 中国社会科学出版社, 2015.
SHI Dan. Research on the development and policy of new energy industry [M]. Beijing: China Social Sciences Press, 2015.
- [2] 刘振亚. 全球能源互联网[M]. 北京: 中国电力出版社, 2015.
LIU Zhenya. Global energy internet [M]. Beijing: China Electric Power Press, 2015.
- [3] 2017 年风电并网运行情况[EB/OL]. [2018-04-27]. http://www.nea.gov.cn/2018-02/01/c_136942234.htm.
Wind power grid operation in 2017[EB/OL]. [2018-04-27]. http://www.nea.gov.cn/2018-02/01/c_136942234.htm.
- [4] TAO Y, CHEN H, QUI C. Wind power prediction and pattern feature based on deep learning method[C]//Power and Energy Engineering Conference. Hong Kong, China; 2014:1-5.
- [5] 刘燕华, 田 茹, 张东英, 等. 风电出力平滑效应的分析与应用[J]. 电网技术, 2013, 37(4): 987-991.
LIU Yanhua, TIAN Ru, ZHANG Dongying, et al. Analysis and application of wind farm output smoothing effect[J]. Power System Technology, 2013, 37(4): 987-991.
- [6] 薛禹胜, 郁 琛, 赵俊华, 等. 关于短期及超短期风电功率预测的评述[J]. 电力系统自动化, 2015, 39(6): 141-151.
XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction[J]. Automation of Electric Power Systems, 2015, 39(6): 141-151.
- [7] 董 朕, 殷 豪, 孟安波. 基于混合算法优化神经网络的风电预测模型[J]. 广东电力, 2017, 30(2): 29-33.
DONG Lian, YIN Hao, MENG Anbo. Wind power forecasting model based on optimized neural network of hybrid algorithm [J]. Guangdong Electric Power, 2017, 30(2): 29-33.
- [8] LORENZ E N. The predictability of a flow which possesses many scales of motion[J]. Tellus, 1969, 21(3): 289-307.
- [9] 杨秀媛, 肖 洋, 陈树勇. 风电场风速和发电功率预测研究[J]. 中国电机工程学报, 2005, 25(11): 1-5.
YANG Xiuyuan, XIAO Yang, CHEN Shuyong. Wind speed and generated power forecasting in wind farm[J]. Proceedings of the CSEE, 2005, 25(11): 1-5.
- [10] KAVASSER R G, SEETHARAMAN K. Day-ahead wind speed

- forecasting using fARIMA models[J]. *Renew Energy*, 2009, 34(5): 1388-1393.
- [11] 李 乐, 刘天琪, 王福军, 等. 一种风电功率简易预测模型[J]. *电测与仪表*, 2016, 53(16): 35-38.
- LI le, LIU Tianqi, WANG Fujun, et al. A simple model for wind power forecasting [J]. *Electrical Measurement & Instrumentation*, 2016, 53(16): 35-38.
- [12] TOL R S J. Autoregressive conditional heteroscedasticity in daily wind speed measurements [J]. *Theoretical & Applied Climatology*, 1997, 56(1-2): 113-122.
- [13] CHEN H, WAN Q, LI F, et al. GARCH in mean type models for wind power forecasting [C] // 2013 IEEE Power & Energy Society General Meeting, IEEE, 2013.
- [14] 陈 昊, 高 山, 王玉荣, 等. 基于广义自回归条件异方差偏度峰度模型的风电功率预测方法 [J]. *中国电机工程学报*, 2017, 37(12): 3456-3461.
- CHEN Hao, GAO Shan, WANG Yurong, et al. Wind power forecasting method based on generalized autoregressive conditional heteroskedasticity with skewness and kurtosis model [J]. *Proceedings of the CSEE*, 2017, 37(12): 3456-3461.
- [15] KARINIOTAKIS G N, STAVRAKAKIS G S, NOGARET E F. Wind power forecasting using advanced neural networks models [J]. *Energy Conversion IEEE Transactions on*, 1996, 11(4): 762-767.
- [16] ZHENG D H, ESEYE A T, ZHANG J H, et al. Short-term wind power forecasting using a double-stage hierarchical ANFIS approach for energy management in microgrids [J]. *Journal of Modern Power Systems and Clean Energy*, 2017, 2-10.
- [17] GIORGI M G D, FICARELLA A, TARANTINO M. Error analysis of short term wind power prediction models [J]. *Applied Energy*, 2011, 88(4): 1298-1311.
- [18] HU Q, ZHANG S, XIE Z, et al. Noise model based ν -support vector regression with its application to short-term wind speed forecasting [J]. *Neural Networks the Official Journal of the International Neural Network Society*, 2014, 57: 1.
- [19] 赵 攀, 戴义平, 夏俊荣, 等. 卡尔曼滤波修正的风电场短期功率预测模型 [J]. *西安交通大学学报*, 2011, 45(5): 47-51.
- ZHAO Pan, DAI Yiping, XIA Junrong, et al. A kalman filter based correction model for short-term wind power prediction [J]. *Journal of Xi'an Jiaotong University*, 2011, 45(5): 47-51.
- [20] ZHOU Y, SMITH S J. Spatial and temporal patterns of global onshore wind speed distribution [J]. *Environmental Research Letters*, 2013, 8(8): 34029.
- [21] LIU J, REN G, WAN J, et al. Variogram time-series analysis of wind speed [J]. *Renewable Energy*, 2016, 99: 483-491.
- [22] ANDREW K, ZHENG H, SONG Z. Wind farm power prediction: a data-mining approach [J]. *Wind Energy*, 2009, 12: 275-293.
- [23] MATHABA T, XIA X, ZHANG J. Short-term wind power prediction using Least-Square Support Vector Machines [C] // Power Engineering Society Conference and Exposition in Africa (Power Africa). Johannesburg, South Africa, 2012: 1-6.
- [24] TABATABAI M A, EBY W M, NIMEH N, et al. A hybrid model for wind speed prediction using empirical mode decomposition and artificial neural networks [J]. *Renewable Energy*, 2012, 48(6): 545-556.
- [25] MATOS M A, BESSA R J. Setting the operating reserve using probabilistic wind power forecasts [J]. *IEEE Transactions on Power Systems*, 2011, 26(2): 594-603.
- [26] PINSON P, KARINIOTAKIS G. Conditional prediction intervals of wind power generation [J]. *Power Systems IEEE Transactions on*, 2010, 25(4): 1845-1856.
- [27] JUBAN J, FUGON L, KARINIOTAKIS G. Probabilistic short-term wind power forecasting based on kernel density estimators [C] // European Wind Energy Conference and Exhibition, MILAN, Italy, 2007: 1-11.
- [28] WAN C, XU Z, Pinson P, et al. Probabilistic forecasting of wind power generation using extreme learning machine [J]. *IEEE Transactions on Power Systems*, 2014, 29(3): 1033-1044.
- [29] FERREIRA C, GAMA J, MATIAS L, et al. A survey on wind power ramp forecasting [J]. *Office of Scientific & Technical Information Technical Reports*, 2011, 05.
- [30] CUI M, ZHANG J, FLORITA A R, et al. An optimized swinging door algorithm for identifying wind ramping events [J]. *IEEE Transactions on Sustainable Energy*, 2015, 7(1): 150-162.
- [31] GREAVES B, COLLINS J, PARKES J, et al. Temporal forecast uncertainty for ramp events [J]. *Wind Engineering*, 2009, 33(4): .
- [32] 崔明建, 孙元章, 柯德平. 基于原子稀疏分解和BP神经网络的风电功率爬坡事件预测 [J]. *电力系统自动化*, 2014, 38(12): 6-11.
- CUI Mingjian, SUN Yuanzhang, KE Deping. Wind power ramp events forecasting based on atomic sparse decomposition and BP neural networks [J]. *Automation of Electric Power Systems*, 2014, 38(12): 6-11.
- [33] 孙志军, 薛 磊, 许阳明, 等. 深度学习研究综述 [J]. *计算机应用研究*, 2012, 29(8): 2806-2810.
- SUN Zhijun, XUE Lei, XU Yangming, et al. Overview of deep learning [J]. *Application Research of Computers*, 2012, 29(8): 2806-2810.
- [34] 余 凯, 贾 磊, 陈雨强, 等. 深度学习的昨天、今天和明天 [J]. *计算机研究与发展*, 2013, 50(9): 1799-1804.
- YU Kai, JIA Lei, CHEN Yuqiang, et al. Deep learning: yesterday, today and tomorrow [J]. *Journal of Computer Research and Development*, 2013, 50(9): 1799-1804.
- [35] 李 刚, 刘 燕, 宋 雨, 等. 基于信息融合的电力大数据可视化预处理方法 [J]. *广东电力*, 2016, 29(12): 10-14.
- LI Gang, LIU Yan, SONG Yu, et al. Visualization pretreatment method for electric power big data based on infor-

- mation fusion[J]. Guangdong Electric Power, 2016, 29(12): 10-14.
- [36] TAO Y, CHEN H. A hybrid wind power prediction method [C] // Power and Energy Society General Meeting. Boston, USA, 2016:1-5.
- [37] TAO H. Energy forecasting: past, present and future[J]. The International Journal of Applied Forecasting, 2014(32): 43-48.
- [38] TAO H, PIERRE P, SHU F, et al. Probabilistic energy forecasting: global energy forecasting competition 2014 and beyond[J]. International Journal of Forecasting, 2016(32): 896-913.
- [39] CIGRE WG C1.32. Establishing best practice approaches for

developing credible electricity demand and energy [M]. CIGRE, 2016.

作者简介:



陶玉波

陶玉波(1986—),男,博士,工程师,从事新能源发电与输电、智能运检工作(E-mail:rgtyb@foxmail.com);

陈昊(1980—),男,博士,研究员级高级工程师,从事电力系统保护与控制、能源预测工作(E-mail:pingfengma@126.com);

秦晓辉(1979—),男,博士,教授级高级工程师,从事电力系统控制及新技术应用工作。

A Review of the Short-term Wind Power Forecasting Theory, Model and Approach

TAO Yubo¹, CHEN Hao¹, QIN Xiaohui¹, MENG ZhaoJun³

(1. State Grid Jiangsu Electric Power Co., Ltd. Maintenance Branch Company, Nanjing 211102, China;

2. China Electric Power Research institute, Beijing 100192, China; 3. NARI Group Corporation, Nanjing 211106, China)

Abstract: Power system is facing growing challenges in maintaining a secure and reliable energy supply. Part of the growing challenge is the possibility of significant levels of uncertain wind generation being installed on power system. Hence the wind power forecasting approaches have drawn to our attention. This paper gives a comprehensive overview of the state-of-the-art wind power forecasting approaches at home and abroad. The basic theory and approaches of wind power forecast, and hot issues are concerned. This paper mainly introduces the research progress of deterministic wind power forecast, probabilistic wind power forecast, wind power ramp events, big data and deep learning approaches.

Key words: wind power forecast; deterministic forecast; probabilistic forecast; wind power ramp events

(编辑 方 晶)